

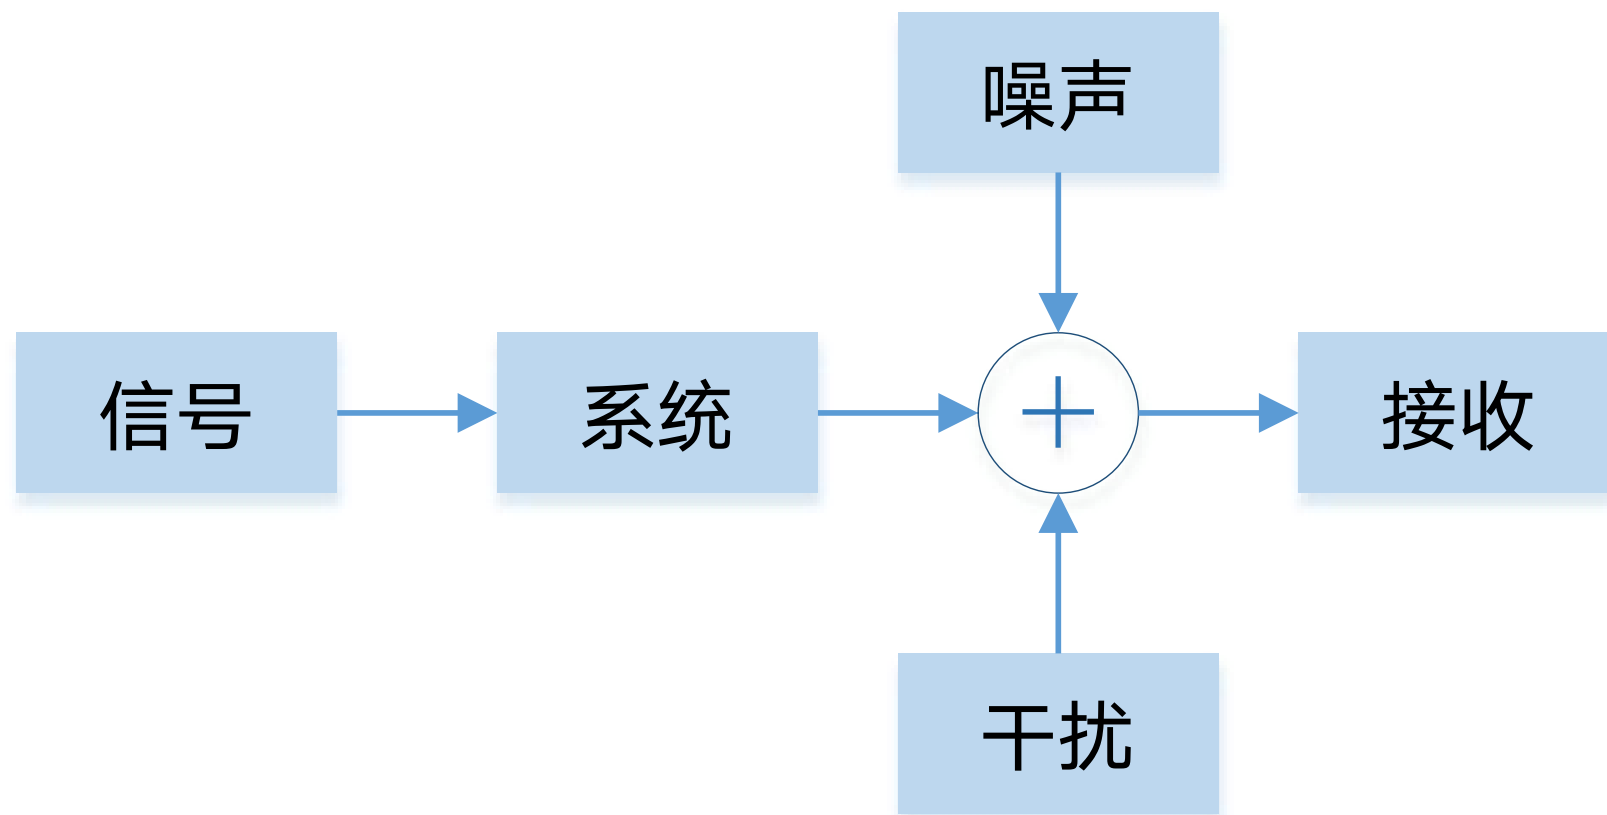
声纳与雷达技术（估计篇）

6/8

浙江大学海洋学院

2023.12.20

- 历史篇
- 入门篇
- 物理篇
- 波形篇
- 检测篇
- 估计篇
- 应用篇



最佳接收

信号、噪声、干扰、系统

内容提纲

□ 经典估计

- 最小均方误差估计
- 最小方差无偏估计
- 线性最小均方误差估计
- 最佳线性无偏估计
- 最小二乘估计
- 矩估计

Classical Estimation

Minimum Mean Square Error Estimation - MMSE
Minimum Variance Unbiased Estimation - MVU (CRB)
Linear Minimum Mean Square Error Estimation - LMMSE
Best Linear Unbiased Estimation - BLUE (CRB)
Least Square Estimation - LSE
Moment Estimation

Cramér–Rao bound, CRB

Cramér–Rao lower bound (CRLB)

□ 贝叶斯估计

- 最小均方误差估计
- 最大后验估计
- 最大似然估计
- 最大似然比估计

Bayesian Estimation

Minimum Mean Square Error Estimation - MMSE
Maximum a Posteriori Estimation – MAP
Maximum Likelihood Estimation – MLE
Maximum Likelihood Ratio Estimation – MLE

□ 声纳估计

- 距离估计器 – 匹配滤波
- 方位估计器 – 波束形成

Sonar Estimation

Matched Filter
Beamformer

贝叶斯Bayes公式→贝叶斯学派

□后验概率 $P(A|B)$ = 先验概率×似然度

□先验概率 $P(A)$


□似然度 $P(B|A)/P(B)$

A果，B因

A已发生的条件下B发生的概率：

条件概率 $P(B | A) = P(A \cap B) / P(A)$

$P(A \cap B) = P(B | A) \times P(A)$



条件概率、全概率

$$P(AB) = P(A|B) P(B) = P(B|A) P(A)$$



A photograph of a chalkboard with the formula for Bayes' theorem written in blue chalk. The formula is $P(A|B) = \frac{P(B|A) P(A)}{P(B)}$.

6、声纳参数估计

回波窄带信号

$$s_r(t) = A_r a(t - t_d) \cos[2\pi(f_0 + f_d)(t - t_d) + \phi(t - t_d)]$$

回波基带复包络

$$u_r(t) = A_r e^{-j2\pi f_0 t_d} u(t - t_d) e^{j2\pi f_d(t - t_d)}$$

时延 Time Delay-距离 多普勒频移 Doppler Shift-速度

$$t_d = 2R/c$$

$$f_d = -(2/\lambda)V_r$$

■距离

■速度

■方位


□正交解调 Orthogonal Demodulation

□数字下变频 Digital Down Convertor

□希尔伯特变换 Hilbert Transform

$$\tilde{\mathbf{x}} \sim \mathcal{CN}(\tilde{\boldsymbol{\mu}}, \mathbf{C}_{\tilde{\mathbf{x}}})$$

$$p(\tilde{\mathbf{x}}) = \frac{1}{\pi^n \det(\mathbf{C}_{\tilde{\mathbf{x}}})} \exp [-(\tilde{\mathbf{x}} - \tilde{\boldsymbol{\mu}})^H \mathbf{C}_{\tilde{\mathbf{x}}}^{-1} (\tilde{\mathbf{x}} - \tilde{\boldsymbol{\mu}})]$$



参量空间：需要接收端作出估计的参量集合

观测空间：接收端收到的观测信号的集合

概率映射：信源发送信号到接收端过程中，会有噪声的影响，观测信号中包含被估计向量的信息，所以观测信号是以被估计向量为参数的随机向量，用 $p(x|\theta)$ 来描述。

估计规则：利用被估计向量的先验知识和观测信号的统计特性，根据指标要求，构造观测向量的函数来定义估计量 $\hat{\theta}(x) = g(x) = g(x_1, x_2, \dots, x_N)$

估计性能：无偏性、有效性、一致性、充分性

均值

方差

均方误差

$$\mu_{\hat{\theta}} = E(\hat{\theta}), \quad \sigma_{\hat{\theta}}^2 = \text{Var}(\hat{\theta}) = E[(\hat{\theta} - \mu_{\hat{\theta}})^2], \quad \varepsilon_{\hat{\theta}}^2 = E[(\theta - \hat{\theta})^2]$$

参量空间 θ

观测空间 R

$p(x|\theta)$

估计规则

$\hat{\theta}(x)$

$$\theta = \begin{pmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_M \end{pmatrix}$$

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix}$$

- 参量空间、概率映射、观测空间、估计准则
- 概率映射函数完整描述含有被估计向量信息时观测向量统计特性
- 数据模型选择原则：1复杂性，足以描述数据基本特征；2简单性，足以允许估计最佳且易实现；3线性， $x=H\theta+w$ ，最优估计解析解

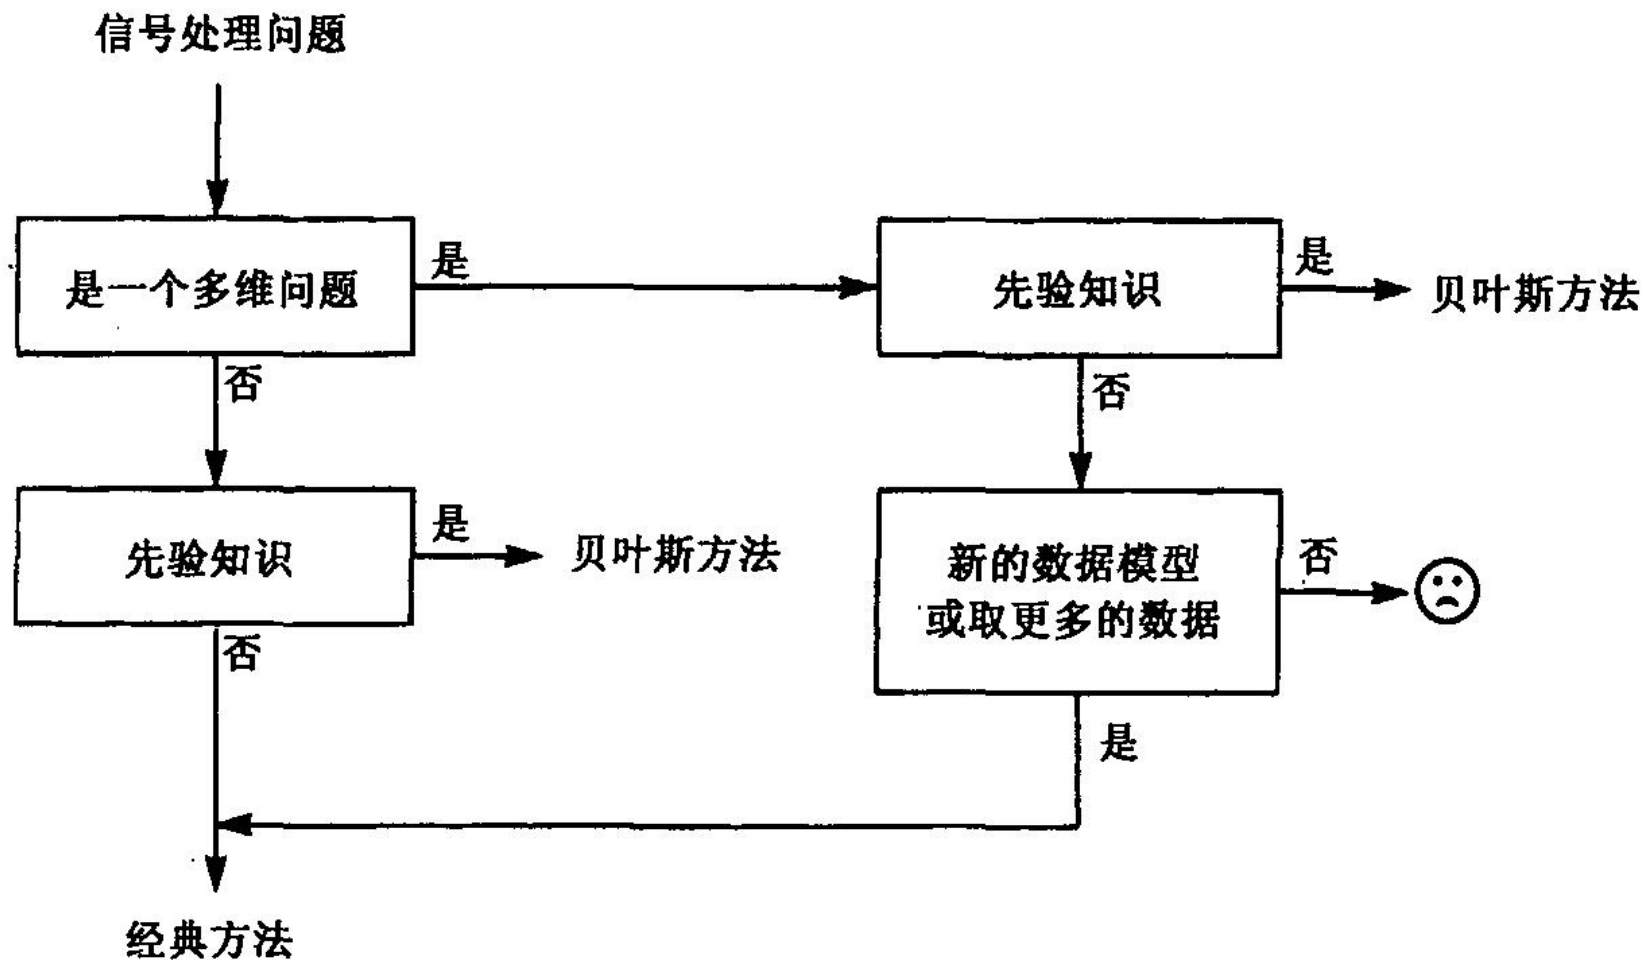
经典估计 vs 贝叶斯估计

■ 经典估计

未知的确定向量估计

■ 贝叶斯估计

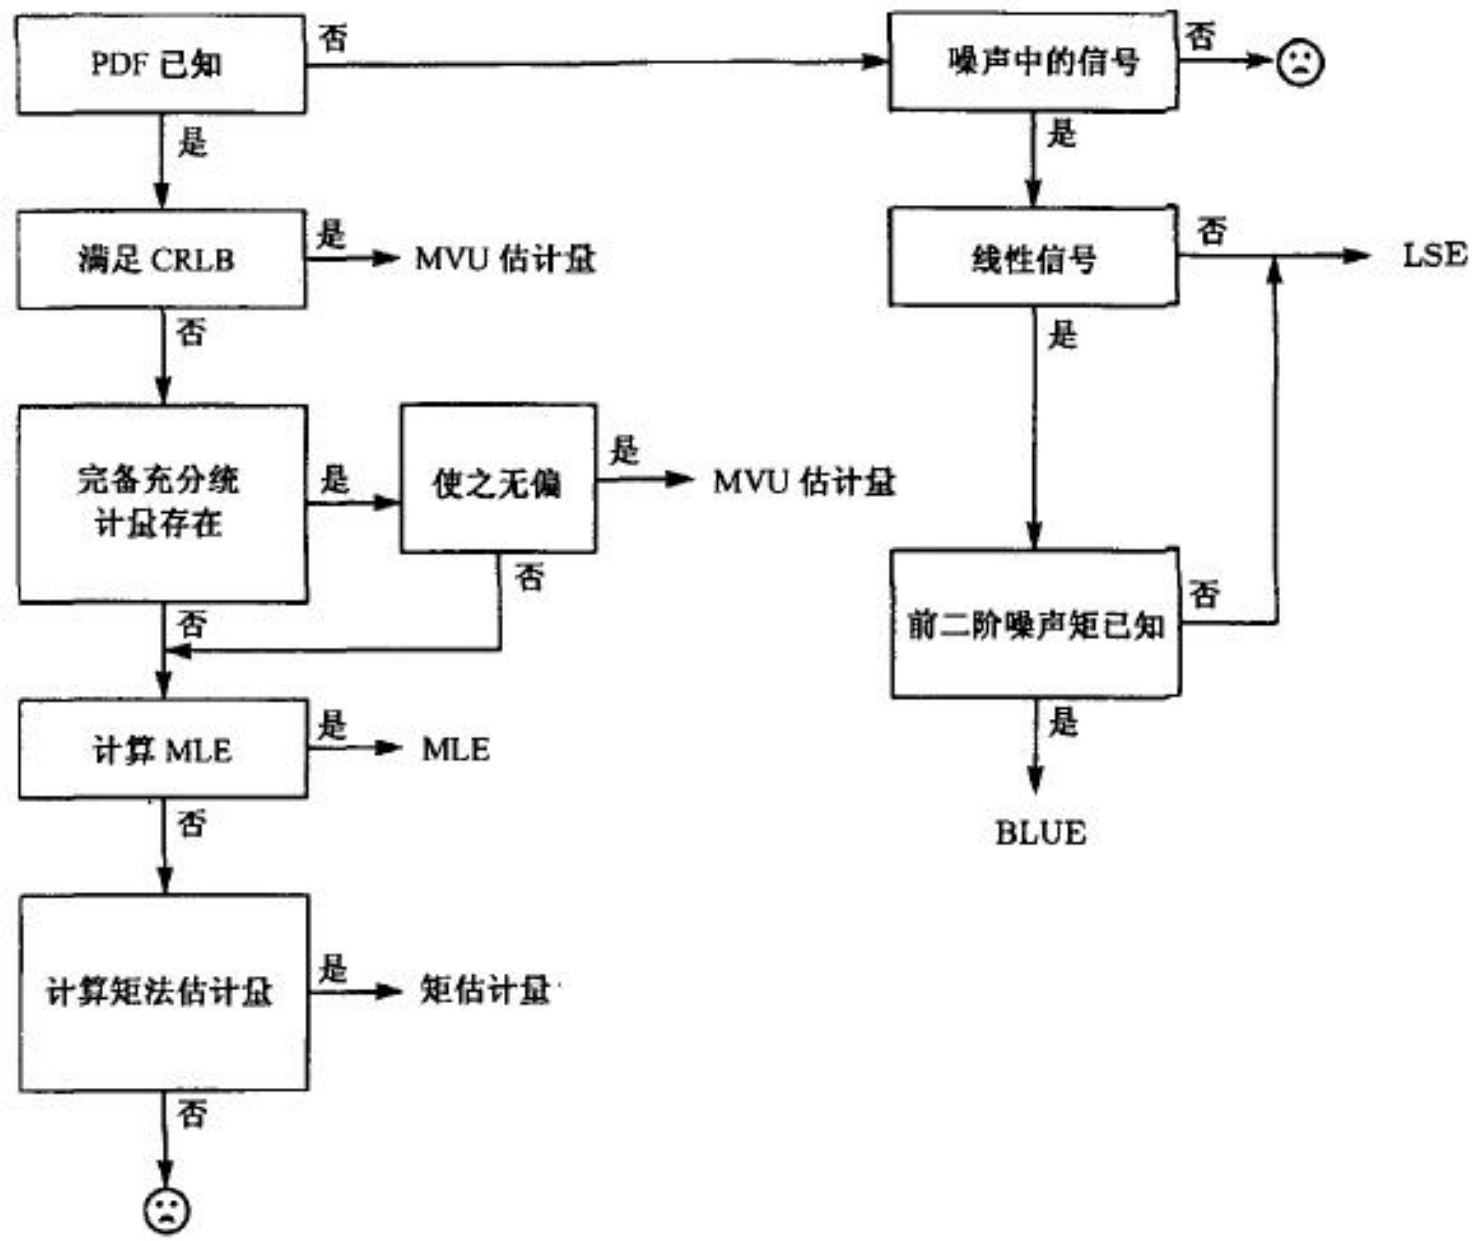
未知的随机向量估计



多维问题？先验知识？新的数据模型或更多的数据？

6.1、经典估计方法

- 最小方差无偏估计 MVU
- 最佳线性无偏估计 BLUE
- 最大似然估计 MLE
- 最小二乘估计 LSE
- 矩方法



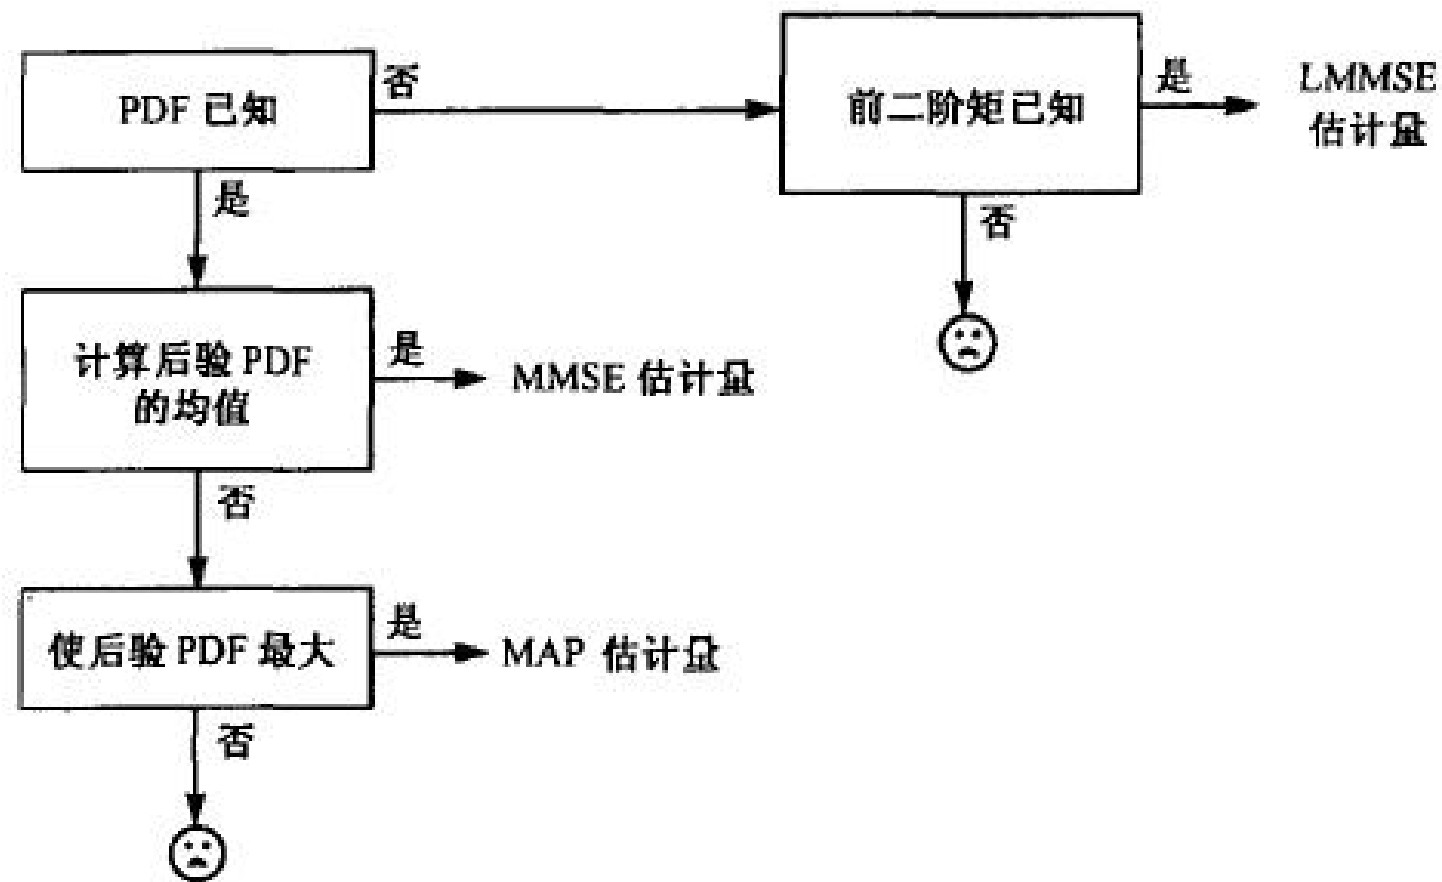
6.2、贝叶斯估计方法

□ 最小均方误差估计 MMSE

□ 最大后验估计 MAP

□ 线性最小均方误差估计
LMMSE

联合高斯分布下 $\text{MAP} = \text{MMSE}$



克拉美罗界 Cramér–Rao bound - CRB

1、估计量的无偏性 $b(\theta) \begin{cases} = 0, \text{ unbiased} \\ \neq 0, \text{ biased} \end{cases}$

$$E(\hat{\theta}) = \int_{-\infty}^{\infty} \hat{\theta} p(\mathbf{x} | \theta) d\mathbf{x} = \theta + b(\theta)$$

$$E(\hat{\theta}) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \hat{\theta} p(\mathbf{x}, \theta) d\mathbf{x} d\theta = E(\theta)$$

$$\lim_{N \rightarrow \infty} E[\hat{\theta}(\mathbf{x}_N)] = \theta, \quad \text{非随机参量}$$

$$\lim_{N \rightarrow \infty} E[\hat{\theta}(\mathbf{x}_N)] = E(\theta), \quad \text{随机参量}$$

2、估计量的有效性

$$E[(\theta - \hat{\theta}_1)^2] < E[(\theta - \hat{\theta}_2)^2]$$

则称估计量 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

克拉美-罗不等式

克拉美-罗界

无偏有效估计量

估计量方差	{	$\text{Var}(\hat{\theta})$
估计误差方差		$\text{Var}(\theta - \hat{\theta})$
均方误差		$E[(\theta - \hat{\theta})^2]$

均方误差准则 (MSE) :

度量估计量偏移真值的平方偏差的统计平均值。

$$\text{mse}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

$$\begin{aligned} \text{mse}(\hat{\theta}) &= E\left\{\left[(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)\right]^2\right\} \\ &= \text{var}(\hat{\theta}) + [E(\hat{\theta}) - \theta]^2 \\ &= \text{var}(\hat{\theta}) + b^2(\theta) \end{aligned}$$

方差



偏差



最小方差无偏估计(MVU): 约束—偏差为零

对无偏估计量确定一个下限CRB

CRLB定理 (Cramer-Rao 下限定理)

假定PDF $p(\mathbf{x};\theta)$ 满足“正则”条件: $E\left[\frac{\partial \ln p(\mathbf{x};\theta)}{\partial \theta}\right]=0$

- Fisher信息矩阵
- 数据信息矩阵
 - 先验信息矩阵

则, 任何无偏估计量 $\hat{\theta}$ 的方差必定满足:

$$\text{var}(\hat{\theta}) \geq \frac{1}{-E\left[\frac{\partial^2 \ln p(\mathbf{x};\theta)}{\partial \theta^2}\right]}$$

且对于某个函数 g 和 I , 当且仅当

$$\frac{\partial \ln p(\mathbf{x};\theta)}{\partial \theta} = I(\theta)(g(\mathbf{x}) - \theta)$$

时, 对所有 θ 达到下限的无偏估计量可以求得:

$$\hat{\theta} = g(\mathbf{x})$$

$$\text{var}(\hat{\theta}) = \frac{1}{I(\theta)}$$

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \frac{\partial^2 \ln p(\mathbf{x},\theta)}{\partial \theta^2} p(\mathbf{x},\theta) d\mathbf{x} d\theta + \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \left(\frac{\partial \ln p(\mathbf{x},\theta)}{\partial \theta}\right)^2 p(\mathbf{x},\theta) d\mathbf{x} d\theta = 0$$

$$\begin{aligned} E\left[\frac{\partial^2 \ln p(\mathbf{x},\theta)}{\partial \theta^2}\right] &= -E\left[\left(\frac{\partial \ln p(\mathbf{x},\theta)}{\partial \theta}\right)^2\right] \\ p(\mathbf{x},\theta) &= p(\mathbf{x}|\theta)p(\theta) \\ \frac{\partial \ln p(\mathbf{x},\theta)}{\partial \theta} &= \frac{\partial \ln p(\mathbf{x}|\theta)}{\partial \theta} + \frac{\partial \ln p(\theta)}{\partial \theta} \\ E[(\theta - \hat{\theta})^2] &\geq \frac{1}{E\left[\left(\frac{\partial \ln p(\mathbf{x}|\theta)}{\partial \theta} + \frac{\partial \ln p(\theta)}{\partial \theta}\right)^2\right]} \\ E[(\theta - \hat{\theta})^2] &\geq \frac{1}{-E\left[\frac{\partial^2 \ln p(\mathbf{x}|\theta)}{\partial \theta^2} + \frac{\partial^2 \ln p(\theta)}{\partial \theta^2}\right]} \\ \frac{\partial \ln p(\mathbf{x}|\theta)}{\partial \theta} + \frac{\partial \ln p(\theta)}{\partial \theta} &= (\theta - \hat{\theta})k \end{aligned}$$

随机参量的贝叶斯估计

贝叶斯准则：在信号参量估计中，使估计的**平均代价最小**。适用于随机参量。

$$C(H_j) = \sum_{i=0}^1 c_{ij} P(H_i | H_j), \quad j = 0, 1$$

$$C = P(H_0)C(H_0) + P(H_1)C(H_1) = \sum_{j=0}^1 \sum_{i=0}^1 c_{ij} P(H_j) P(H_i | H_j)$$

代价函数的一般形式：


$$c(\tilde{\theta}) = c(\theta - \hat{\theta})$$

- (1) 非负；
- (2) 误差 $\tilde{\theta} = 0$ 时最小。


$$c(\tilde{\theta}) = c(\theta - \hat{\theta}) = (\theta - \hat{\theta})^2$$

$$c(\tilde{\theta}) = c(\theta - \hat{\theta}) = |\theta - \hat{\theta}|$$


$$c(\tilde{\theta}) = c(\theta - \hat{\theta}) = \begin{cases} 1, & |\tilde{\theta}| \geq \frac{\Delta}{2} \\ 0, & |\tilde{\theta}| < \frac{\Delta}{2} \end{cases}$$



(a) 误差平方代价函数



(b) 误差绝对值代价函数



(c) 均匀代价函数

平均代价

$$C = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} c(\theta, \tilde{\theta}) p(\mathbf{x}, \theta) d\mathbf{x} d\theta$$

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} c(\theta - \hat{\theta}) p(\mathbf{x}, \theta) d\mathbf{x} d\theta$$

贝叶斯公式

$$p(\mathbf{x}, \theta) = p(\theta | \mathbf{x}) p(\mathbf{x})$$

$$C = \int_{-\infty}^{\infty} p(\mathbf{x}) \left[\int_{-\infty}^{\infty} c(\theta - \hat{\theta}) p(\theta | \mathbf{x}) d\theta \right] d\mathbf{x}$$

条件平均代价

$$C(\hat{\theta} | \mathbf{x}) \stackrel{\text{def}}{=} \int_{-\infty}^{\infty} c(\theta - \hat{\theta}) p(\theta | \mathbf{x}) d\theta$$

上述条件平均代价函数 $C(\hat{\theta} | \mathbf{x})$ 对 $\hat{\theta}$ 求最小，即可以求得随机参量 θ 的贝叶斯估计量 $\hat{\theta}_b$ 。

1、最小均方误差估计

$$C(\hat{\theta} | \mathbf{x}) = \int_{-\infty}^{\infty} (\theta - \hat{\theta})^2 p(\theta | \mathbf{x}) d\theta$$

$$\frac{\partial}{\partial \hat{\theta}} \int_{-\infty}^{\infty} (\theta - \hat{\theta})^2 p(\theta | \mathbf{x}) d\theta$$

$$= -2 \int_{-\infty}^{\infty} \theta p(\theta | \mathbf{x}) d\theta + 2\hat{\theta} \int_{-\infty}^{\infty} p(\theta | \mathbf{x}) d\theta \Big|_{\hat{\theta} = \hat{\theta}_{\text{mse}}} = 0$$

$$\hat{\theta}_{\text{mse}} = \int_{-\infty}^{\infty} \theta p(\theta | \mathbf{x}) d\theta$$

将后验概率转化为先验概率表达

$$p(\theta | \mathbf{x}) = p(\mathbf{x} | \theta) p(\theta) / p(\mathbf{x})$$

$$p(\mathbf{x}) = \int_{-\infty}^{\infty} p(\mathbf{x}, \theta) d\theta = \int_{-\infty}^{\infty} p(\mathbf{x} | \theta) p(\theta) d\theta$$

$$\hat{\theta}_{\text{mse}} = \frac{\int_{-\infty}^{\infty} \theta p(\mathbf{x} | \theta) p(\theta) d\theta}{\int_{-\infty}^{\infty} p(\mathbf{x} | \theta) p(\theta) d\theta}$$

$$\int_{-\infty}^{\infty} p(\theta | \mathbf{x}) d\theta = 1$$

2、最大后验估计

$$C(\hat{\theta} | \mathbf{x}) = \int_{-\infty}^{\hat{\theta} - \frac{\Delta}{2}} p(\theta | \mathbf{x}) d\theta + \int_{\hat{\theta} + \frac{\Delta}{2}}^{\infty} p(\theta | \mathbf{x}) d\theta$$

$$= 1 - \int_{\hat{\theta} - \frac{\Delta}{2}}^{\hat{\theta} + \frac{\Delta}{2}} p(\theta | \mathbf{x}) d\theta$$

等效于使 $\int_{\hat{\theta} - \frac{\Delta}{2}}^{\hat{\theta} + \frac{\Delta}{2}} p(\theta | \mathbf{x}) d\theta$ 最大

$$\left. \frac{\partial p(\theta | \mathbf{x})}{\partial \theta} \right|_{\theta = \hat{\theta}_{\text{map}}} = 0$$

$$p(\theta | \mathbf{x}) = p(\mathbf{x} | \theta) p(\theta) / p(\mathbf{x})$$

$$\left. \frac{\partial \ln p(\theta | \mathbf{x})}{\partial \theta} \right|_{\theta = \hat{\theta}_{\text{map}}} = 0$$

$$\left[\frac{\partial \ln p(\mathbf{x} | \theta)}{\partial \theta} + \frac{\partial \ln p(\theta)}{\partial \theta} \right] \bigg|_{\theta = \hat{\theta}_{\text{map}}} = 0$$

6.3、最大似然估计

最大似然估计常用来估计未知的非随机参量。

最大似然估计定义：使似然函数 $p(\mathbf{x}|\theta)$ 最大的 θ 值作为估计量的参量估计方法(Maximum Likelihood Estimation)。

最大似然估计原理


最大似然函数的基本原理是：对于某个选定的 θ ，考虑 \mathbf{x} 落在一个小区域内的概率 $p(\mathbf{x}|\theta)d\mathbf{x}$ ，取 $p(\mathbf{x}|\theta)d\mathbf{x}$ 最大的那个 θ 作为估计量 $\hat{\theta}_{\text{ml}}$ 。

似然函数是在给定 $\mathbf{x} = \mathbf{x}_0$ 后得到的，可以画出它与被估计量 θ 的关系曲线。

PDF作为未知参数的函数（ \mathbf{x} 固定），称之为似然函数。

$$\left. \frac{\partial p(\mathbf{x}|\theta)}{\partial \theta} \right|_{\theta=\hat{\theta}_{\text{ml}}} = 0 \quad \left. \frac{\partial \ln p(\mathbf{x}|\theta)}{\partial \theta} \right|_{\theta=\hat{\theta}_{\text{ml}}} = 0$$

$$\left[\frac{\partial \ln p(\mathbf{x}|\theta)}{\partial \theta} + \frac{\partial \ln p(\theta)}{\partial \theta} \right] \bigg|_{\theta=\hat{\theta}_{\text{map}}} = 0$$



相当于最大似然估计用于估计没有任何先验知识的随机参量 θ ，

假定 θ 为均匀分布，上式第二项为零，最大后验概率估计转化为最大似然估计。


距离估计

在雷达和主动声纳中发射信号脉冲,从发射机到目标再返回的双程延迟 τ_0 与距离 R 有关,即 $\tau_0 = 2R/c$,其中 c 是传播速度。假定 c 是已知的,因此距离的估计等价于时延的估计。如果 $s(t)$ 是发射信号,那么对于接收连续波形的一个简单模型是

$$x(t) = s(t - \tau_0) + w(t) \quad 0 \leq t \leq T$$

发射信号脉冲假定在区间 $[0, T_s]$ 上是非零的。另外,假定信号限制在带宽 B Hz 的频带内,如果最大延迟时间是 $\tau_{0\max}$,那么通过令 $T = T_s + \tau_{0\max}$,观测间隔的选择将包括整个信号。噪声可以建模为具有图 3.7 的 PSD 和 ACF 的高斯噪声,噪声的带限特性是由于对 B Hz 带宽信号的连续波形进行滤波所造成的。以奈奎斯特(Nyquist)采样速率对连续的接收波形进行采样,即以 $\Delta = 1/(2B)$ 秒采样形成观测数据

$$x(n\Delta) = s(n\Delta - \tau_0) + w(n\Delta) \quad n = 0, 1, \dots, N-1$$



令 $x[n]$ 和 $w[n]$ 是采样序列,那么我们有离散的数据模型

$$x[n] = s(n\Delta - \tau_0) + w[n] \quad (3.35)$$

注意, $w[n]$ 是 WGN, 由于样本之间的间隔是 $k\Delta = k/(2B)$, 它对应于图 3.7 中 $w(t)$ 的 ACF 的零点。另外, $w[n]$ 的方差为 $\sigma^2 = r_{ww}(0) = N_0 B$ 。由于信号只在区间 $\tau_0 \leq t \leq \tau_0 + T_s$ 上是非零的,因此(3.35)式化简为

$$x[n] = \begin{cases} w[n] & 0 \leq n \leq n_0 - 1 \\ s(n\Delta - \tau_0) + w[n] & n_0 \leq n \leq n_0 + M - 1 \\ w[n] & n_0 + M \leq n \leq N - 1 \end{cases} \quad (3.36)$$

其中 M 是采样信号的长度, $n_0 = \tau_0/\Delta$ 是样本中的延迟(为了简单起见,我们假定 Δ 非常小,以至于 τ_0/Δ 可由一个整数近似)。由于 $\tau_0 = n_0\Delta$,通过这个公式我们可以应用(3.14)式计算 CRLB。

$$\begin{aligned} \text{var}(\hat{\tau}_0) &\geq \frac{\sigma^2}{\sum_{n=0}^{N-1} \left(\frac{\partial s[n; \tau_0]}{\partial \tau_0} \right)^2} \\ &= \frac{\sigma^2}{\sum_{n=n_0}^{n_0+M-1} \left(\frac{\partial s(n\Delta - \tau_0)}{\partial \tau_0} \right)^2} \\ &= \frac{\sigma^2}{\sum_{n=n_0}^{n_0+M-1} \left(\left. \frac{ds(t)}{dt} \right|_{t=n\Delta - \tau_0} \right)^2} \\ &= \frac{\sigma^2}{\sum_{n=0}^{M-1} \left(\left. \frac{ds(t)}{dt} \right|_{t=n\Delta} \right)^2} \end{aligned}$$

假定 Δ 小到足以用一个积分来近似和式,我们有

$$\text{var}(\hat{\tau}_0) \geq \frac{\sigma^2}{\frac{1}{\Delta} \int_0^{T_s} \left(\frac{ds(t)}{dt} \right)^2 dt}$$

最后,注意 $\Delta = 1/(2B)$, $\sigma^2 = N_0 B$, 我们有

$$\text{var}(\hat{\tau}_0) \geq \frac{\frac{N_0}{2}}{\int_0^{T_s} \left(\frac{ds(t)}{dt} \right)^2 dt} \quad (3.37)$$

• 4.3 复杂信号波形

时延估计标准差

$$\sigma_{\tau} = \frac{1}{B_{rms} \sqrt{2E_x/\eta_0}} \quad B_{rms}^2 = \frac{(2\pi)^2 \int_{-\infty}^{\infty} f^2 |X(f)|^2 df}{\int_{-\infty}^{\infty} |X(f)|^2 df}$$

Doppler频移估计标准差

$$\sigma_{f_d} = \frac{1}{\tau_{rms} \sqrt{2E_x/\eta_0}} \quad \tau_{rms}^2 = \left((2\pi)^2 \int_{-\infty}^{\infty} t^2 |x(t)|^2 dt \right) / \left(\int_{-\infty}^{\infty} |x(t)|^2 dt \right)$$

注意到信号能量 \mathcal{E} 是

$$\mathcal{E} = \int_0^{T_s} s^2(t) dt$$

这样导出(3.37)式的另一种形式

$$\text{var}(\hat{\tau}_0) \geq \frac{1}{\frac{\mathcal{E}}{N_0/2} \overline{F^2}} \quad \text{时延估计方差} \quad (3.38)$$

其中

$$\overline{F^2} = \frac{\int_0^{T_s} \left(\frac{ds(t)}{dt} \right)^2 dt}{\int_0^{T_s} s^2(t) dt}$$

可以证明 $\mathcal{E}/(N_0/2)$ 是 SNR [Van Trees 1968]。另外,利用标准傅里叶变换性质,


$$\overline{F^2} = \frac{\int_{-\infty}^{\infty} (2\pi F)^2 |S(F)|^2 dF}{\int_{-\infty}^{\infty} |S(F)|^2 dF} \quad (3.39)$$

其中 F 表示连续时间频率, $S(F)$ 是 $s(t)$ 的傅里叶变换, 所以 $\overline{F^2}$ 是信号带宽的度量。在这一表达式中, 可以很清楚地看出 $\overline{F^2}$ 是信号的均方带宽。由(3.38)式和(3.39)式可知, 均方带宽越大, CRLB 越小。例如, 假定信号是由 $s(t) = \exp\left(-\frac{1}{2}\sigma_F^2(t - T_s/2)^2\right)$ 给出的高斯脉冲, $s(t)$ 在区间 $[0, T_s]$ 上非零, 那么 $|S(F)| = (\sigma_F/\sqrt{2\pi}) \exp(-2\pi^2 F^2/\sigma_F^2)$ 且 $\overline{F^2} = \sigma_F^2/2$ 。当均方带宽增加时, 信号脉冲变窄, 这样就更容易估计时延。

最后, 注意到 $R = c\tau_0/2$, 利用(3.16)式, 距离的 CRLB 为

$$\text{var}(\hat{R}) \geq \frac{c^2/4}{\frac{\mathcal{E}}{N_0/2} \overline{F^2}} \quad \text{距离估计方差} \quad (3.40)$$

方位估计



在声纳中,我们感兴趣是估计图 3.8 所示的目标方位。为此,声压场由排成一线的等间距的传感器观测到,假定目标辐射一个正弦信号 $A\cos(2\pi F_0 t + \phi)$,那么,在第 n 个传感器收到的信号是 $A\cos(2\pi F_0(t - t_n) + \phi)$,其中 t_n 是辐射到第 n 个传感器的时间。如果阵的位置离目标很远,那么,圆的波前在阵的位置就可以看成平面波。如图 3.8 所示,第 $n-1$ 个传感器与第 n 个传感器由于额外的传播距离而引起的波程差为 $d\cos\beta/c$ 。这样,第 n 个传感器的传播时间为

$$t_n = t_0 - n \frac{d}{c} \cos \beta \quad n = 0, 1, \dots, M-1$$

其中 t_0 是到第 0 个传感器的传播时间,在第 n 个传感器观测到的信号是

$$s_n(t) = A \cos \left[2\pi F_0 \left(t - t_0 + n \frac{d}{c} \cos \beta \right) + \phi \right]$$

如果取数据的单个“快拍”,或者在某个时刻 t_s 对阵元的输出进行采样,那么

$$s_n(t_s) = A \cos \left[2\pi \left(F_0 \frac{d}{c} \cos \beta \right) n + \phi' \right] \quad (3.42)$$

其中 $\phi' = \phi + 2\pi F_0(t_s - t_0)$ 。在这个公式中,很显然空间观测是频率为 $f_s = F_0(d/c)\cos\beta$ 的正弦型信号。为了完成数据的描述,我们假定传感器的输出受到零均值、方差为 σ^2 的高斯噪声的污染,传感器与传感器之间的这些噪声是相互独立的,数据的模型为

$$x[n] = s_n(t_s) + w[n] \quad n = 0, 1, \dots, M-1$$

其中 $w[n]$ 是 WGN。由于典型的情况是 A, ϕ 是未知的,那么,我们有像例(3.14)式那样根据(3.42)式估计 $|A, f_s, \phi'|$ 的问题。一旦确定了这些参数的 CRLB,我们就可以利用参数来变换公式。对 $\theta = [A, f_s, \phi']^T$ 的变换是

$$\alpha = g(\theta) = \begin{bmatrix} A \\ \beta \\ \phi' \end{bmatrix} = \begin{bmatrix} A \\ \arccos \left(\frac{c f_s}{F_0 d} \right) \\ \phi' \end{bmatrix}$$

雅可比矩阵为

$$\frac{\partial g(\theta)}{\partial \theta} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -\frac{c}{F_0 d \sin \beta} & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

所以,根据(3.30)式得

$$\left[C_{\hat{\alpha}} - \frac{\partial g(\theta)}{\partial \theta} I^{-1}(\theta) \frac{\partial g(\theta)^T}{\partial \theta} \right]_{22} \geq 0$$

由于对角雅可比矩阵,可得

$$\text{var}(\hat{\beta}) \geq \left[\frac{\partial g(\theta)}{\partial \theta} \right]_{22}^2 [I^{-1}(\theta)]_{22}$$

但是根据(3.41)式,我们有

$$[I^{-1}(\theta)]_{22} = \frac{12}{(2\pi)^2 \eta M (M^2 - 1)}$$

因此

$$\text{var}(\hat{\beta}) \geq \frac{12}{(2\pi)^2 \eta M (M^2 - 1)} \frac{c^2}{F_0^2 d^2 \sin^2 \beta}$$

方位估计方差

或者最终有

$$\text{var}(\hat{\beta}) \geq \frac{12}{(2\pi)^2 M \eta \frac{M+1}{M-1} \left(\frac{L}{\lambda} \right)^2 \sin^2 \beta} \quad (3.43)$$

其中 $\lambda = c/F_0$ 是传播平面波的波长, $L = (M-1)d$ 是阵的长度。注意,如果 $\beta = 90^\circ$,那么这是最容易估计的方位,而 $\beta = 0^\circ$ 是不可能估计的方位。另外,下限和阵的长度与波长之比(即 L/λ)以及阵的输出 SNR(即 $M\eta$)有关,在习题 3.19 中考察了 CRLB 使用的可行性研究。

我们继续考虑例 3.15 中的阵列处理问题,但是这里假定传感器的噪声是非白噪声。我们或者最终约束希望在设计波束形成器时考虑噪声的色度。波束形成器是发射信号的估计器,在许多情况下,非白噪声是有意干扰的结果。回想到对于发射的正弦信号 $A\cos(2\pi F_0 t + \phi)$,在一线阵上接收的信号为

$$s_n(t) = A \cos[2\pi f_s n + 2\pi F_0(t - t_0) + \phi] \quad n = 0, 1, \dots, M - 1$$

其中, n 为传感器号, $f_s = F_0(d/c)\cos\beta$ (d 为传感器间距, c 为传播速度, β 为到达角) 是空间频率, t_0 为传播到第 0 个传感器的时间。如果我们选择处理接收数据中的解析信号,则令 $\phi' = -2\pi F_0 t_0 + \phi$ (ϕ 和 t_0 一般为未知), 对信号分量我们有

$$\tilde{s}_n(t) = A \exp(j\phi') \exp(j2\pi f_s n) \exp(j2\pi F_0 t) = \tilde{A} \exp(j2\pi f_s n) \exp(j2\pi F_0 t)$$

对于时间上的每一瞬间,我们在 M 个传感器上有信号矢量“快拍”(snapshot),

$$\tilde{\mathbf{s}}(t) = [\tilde{s}_0(t) \quad \tilde{s}_1(t) \quad \dots \quad \tilde{s}_{M-1}(t)]^T = \tilde{A} \exp(j2\pi F_0 t) \mathbf{e}$$

其中 $\mathbf{e} = [1 \exp(j2\pi f_s) \dots \exp[j(2\pi f_s(M-1))]]^T$ 。假定数据模型为

$$\tilde{\mathbf{x}}(t) = \tilde{A} \exp(j2\pi F_0 t) \mathbf{e} + \tilde{\mathbf{w}}(t)$$

其中 $\tilde{\mathbf{w}}(t)$ 为零均值、协方差矩阵为 \mathbf{C} 的噪声矢量。假定均值和协方差不随时间 t 变化。我们希望设计一个波束形成器,将传感器的输出线性地组合为

$$\tilde{y}(t) = \sum_{n=0}^{M-1} a_n^* \tilde{x}_n(t) = \mathbf{a}^H \tilde{\mathbf{x}}(t)$$

从而使信号无失真通过,但输出的噪声达到最小。无失真意味着如果 $\tilde{\mathbf{x}}(t) = \tilde{\mathbf{s}}(t) = \tilde{A} \exp(j2\pi F_0 t) \mathbf{e}$, 那么在波束形成器的输出中,我们应该有

$$\tilde{y}(t) = \tilde{A} \exp(j2\pi F_0 t)$$

这就要求

$$\mathbf{a}^H \tilde{\mathbf{s}}(t) = \tilde{A} \exp(j2\pi F_0 t)$$

或者

$$\mathbf{a}^H \mathbf{e} = 1$$

波束形成器是源信号估计器

$$\mathbf{e}^H \mathbf{a} = 1$$

波束形成器输出端的噪声方差为

$$E[|\mathbf{a}^H \tilde{\mathbf{w}}(t)|^2] = E[\mathbf{a}^H \tilde{\mathbf{w}}(t) \tilde{\mathbf{w}}^H(t) \mathbf{a}] = \mathbf{a}^H \mathbf{C} \mathbf{a}$$

这也是 $\tilde{y}(t)$ 的方差。因此,最佳波束形成器的加权由下面问题的解给出:在约束 $\mathbf{e}^H \mathbf{a} = 1$ 的条件下,使 $\mathbf{a}^H \mathbf{C} \mathbf{a}$ 最小。于是,有时这也称为最小方差无失真响应(MVDR)波束形成器[Owsley 1985]。读者将发现,我们早已结合 BLUE 解出此问题,事实上由(15.51)式,令 $\mathbf{W} = \mathbf{C}$, $\mathbf{B} = \mathbf{e}^H$, $\mathbf{b} = 1$, 我们有最佳解为

$$\mathbf{a}_{\text{opt}} = \frac{\mathbf{C}^{-1} \mathbf{e}}{\mathbf{e}^H \mathbf{C}^{-1} \mathbf{e}}$$

波束形成器的输出端为

空间非白噪声

$$\tilde{y}(t) = \frac{\mathbf{e}^H \mathbf{C}^{-1} \tilde{\mathbf{x}}(t)}{\mathbf{e}^H \mathbf{C}^{-1} \mathbf{e}} \quad \text{ABF 自适应波束形成} \quad (15.75)$$

可以验证, $\tilde{y}(t)$ 刚好是 $\tilde{A} \exp(j2\pi F_0 t)$ 对给定 t 的 BLUE。在例 15.7 中,对 $F_0 = 0$ 因而也是对 $\mathbf{e} = 1$, 我们也推导了这样的结果。“自适应波束形成器”的名称来自于(15.75)式的实际实现,其中的噪声协方差矩阵通常未知,因此必须在信号出现之前进行估计,那么我们就说波束形成器对噪声场的出现是自适应的。当然,在使用估计的协方差矩阵时,并没有与波束形成器相联系的最佳协方差矩阵。当估计协方差时如果信号出现,那么性能可能很差[Cox 1973]。注意,如果 $\mathbf{C} = \sigma^2 \mathbf{I}$, 传感器的噪声是不相关的,且具有相等的方差(“空间白化”),则(15.75)式简化为

空间白噪声

$$\tilde{y}(t) = \frac{1}{M} \sum_{n=0}^{M-1} \tilde{x}_n(t) \exp(-j2\pi f_s n) \quad \text{CBF 常规波束形成}$$

波束形成器首先在不同的传感器中调整信号的相位,通过改变传播延迟、然后取平均,使它们在时间上进行校准。这就是所谓的常规波束形成器[Knight, Pridham, and Kay 1981]。

$$\tilde{x}[n] = \tilde{A} \exp(j2\pi f_0 n) + \tilde{w}[n] \quad n = 0, 1, \dots, N-1$$

其中, $\tilde{w}[n]$ 是方差为 σ^2 的 CWGN, $\tilde{A} \sim \mathcal{CN}(0, \sigma_A^2)$, \tilde{A} 与 $\tilde{w}[n]$ 独立。用矩阵形式表示, 我们有

$$\tilde{\mathbf{x}} = \tilde{A} \mathbf{e} + \tilde{\mathbf{w}}$$

其中, $\mathbf{e} = [1 \exp(j2\pi f_0) \dots \exp(j2\pi f_0(N-1))]^T$ 。由于独立复高斯随机变量之和也是复高斯的(参见 15.4 节), 我们有

$$\tilde{\mathbf{x}} \sim \mathcal{CN}(\mathbf{0}, \mathbf{C}_{\tilde{x}})$$

为了求协方差矩阵, 由于 \tilde{A} 与 $\tilde{\mathbf{w}}$ 独立, 所以

$$\begin{aligned} \mathbf{C}_{\tilde{x}} &= E(\tilde{\mathbf{x}}\tilde{\mathbf{x}}^H) = E((\tilde{A}\mathbf{e} + \tilde{\mathbf{w}})(\tilde{A}\mathbf{e} + \tilde{\mathbf{w}})^H) \\ &= E(|\tilde{A}|^2)\mathbf{e}\mathbf{e}^H + \sigma^2\mathbf{I} = \sigma_A^2\mathbf{e}\mathbf{e}^H + \sigma^2\mathbf{I} \end{aligned}$$

我们现在考察在假定 f_0 和 σ^2 已知时复幅度的方差 σ_A^2 的估计问题。PDF 为

$$p(\tilde{\mathbf{x}}; \sigma_A^2) = \frac{1}{\pi^N \det(\mathbf{C}_{\tilde{x}}(\sigma_A^2))} \exp[-\tilde{\mathbf{x}}^H \mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \tilde{\mathbf{x}}]$$

为了确定是否达到 CRLB, 我们计算

$$\frac{\partial \ln p(\tilde{\mathbf{x}}; \sigma_A^2)}{\partial \sigma_A^2} = -\frac{\partial \ln \det(\mathbf{C}_{\tilde{x}}(\sigma_A^2))}{\partial \sigma_A^2} - \frac{\partial \tilde{\mathbf{x}}^H \mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \tilde{\mathbf{x}}}{\partial \sigma_A^2}$$

利用(15.47)式和(15.48)式,

$$\begin{aligned} \frac{\partial \ln p(\tilde{\mathbf{x}}; \sigma_A^2)}{\partial \sigma_A^2} &= -\text{tr} \left(\mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \frac{\partial \mathbf{C}_{\tilde{x}}(\sigma_A^2)}{\partial \sigma_A^2} \right) + \tilde{\mathbf{x}}^H \mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \frac{\partial \mathbf{C}_{\tilde{x}}(\sigma_A^2)}{\partial \sigma_A^2} \mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \tilde{\mathbf{x}} \\ &= -\text{tr}(\mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \mathbf{e}\mathbf{e}^H) + \tilde{\mathbf{x}}^H \mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \mathbf{e}\mathbf{e}^H \mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \tilde{\mathbf{x}} \\ &= -\mathbf{e}^H \mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \mathbf{e} + |\mathbf{e}^H \mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \tilde{\mathbf{x}}|^2 \end{aligned}$$

但是

$$\mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) = \frac{1}{\sigma^2} \mathbf{I} - \frac{1}{\sigma^4} \frac{\sigma_A^2 \mathbf{e}\mathbf{e}^H}{1 + \frac{N\sigma_A^2}{\sigma^2}}$$

所以

$$\mathbf{C}_{\tilde{x}}^{-1}(\sigma_A^2) \mathbf{e} = \frac{1}{\sigma^2} \mathbf{e} - \frac{N\sigma_A^2}{\sigma^4 + N\sigma_A^2\sigma^2} \mathbf{e} = \frac{\mathbf{e}}{N\sigma_A^2 + \sigma^2}$$

因此

$$\frac{\partial \ln p(\tilde{\mathbf{x}}; \sigma_A^2)}{\partial \sigma_A^2} = -\frac{N}{N\sigma_A^2 + \sigma^2} + \frac{|\tilde{\mathbf{x}}^H \mathbf{e}|^2}{(N\sigma_A^2 + \sigma^2)^2} = \left(\frac{N}{N\sigma_A^2 + \sigma^2} \right)^2 \left(\frac{|\tilde{\mathbf{x}}^H \mathbf{e}|^2}{N^2} - \frac{\sigma^2}{N} - \sigma_A^2 \right)$$

估计量

$$\hat{\sigma}_A^2 = \frac{|\tilde{\mathbf{x}}^H \mathbf{e}|^2}{N^2} - \frac{\sigma^2}{N} = \frac{1}{N^2} \left| \sum_{n=0}^{N-1} \tilde{x}[n] \exp(-j2\pi f_0 n) \right|^2 - \frac{\sigma^2}{N}$$

是满足 CRLB 的, 它是有效估计量并且具有最小方差,


$$\text{var}(\hat{\sigma}_A^2) = \left(\sigma_A^2 + \frac{\sigma^2}{N} \right)^2$$

信号幅度估计

6.4、波束形成Beamforming

波束形成器Beamformer

- 空间滤波器Spatial Filter
- 波达角估计DOA
- 阵列信号处理Array Signal Processing
- 远场假设
- 点源假设
- 平面波假设
- 相干性假设
- 均匀性假设



(一) 常规波束形成CBF

常规波束形成器 (Conventional Beamformer——CBF)


$$\mathbf{D}_{\text{CBF}}(\theta) = \mathbf{e}^H \mathbf{R} \mathbf{e}$$

$$\mathbf{e} = [1, e^{-j\omega\tau}, e^{-j2\omega\tau}, \dots, e^{-j(N-1)\omega\tau}]^T \quad \tau = c^{-1} d \cos \theta$$

$$\mathbf{x} = [x_1, x_2, \dots, x_{N-1}]^T$$

$$\mathbf{R} = \mathbf{E}[\mathbf{x}^H \mathbf{x}]$$

$$\hat{R}_{ij} = \sum_{l=1}^L x_i^*(l) x_j(l)$$



(一) 最小方差无失真响应波束形成器 MVDR

最小方差无失真响应 Minimum Variance Distortionless Response
亦称自适应波束形成器 Adaptive Beamformer——ABF

$$D_{\text{MVDR}}(\theta) = \mathbf{w}^H \mathbf{R} \mathbf{w}$$

$$\min_{\mathbf{w}} \mathbf{w}^H \mathbf{R} \mathbf{w} \quad + \quad \mathbf{w}^H \mathbf{e} = 1 \quad \rightarrow \quad \mathbf{w} = \mathbf{R}^{-1} \mathbf{e} (\mathbf{e}^H \mathbf{R}^{-1} \mathbf{e})^{-1}$$

$$D_{\text{MVDR}}(\theta) = (\mathbf{e}^H \mathbf{R}^{-1} \mathbf{e})^{-1}$$

协方差矩阵对角加载 $\mathbf{w}_{\varepsilon} = (\mathbf{R} + \varepsilon \mathbf{I})^{-1} \mathbf{e} [\mathbf{e}^H (\mathbf{R} + \varepsilon \mathbf{I}) \mathbf{e}]^{-1}$

$$D_{\text{MVDR}}(\theta) = \mathbf{w}_{\varepsilon}^H \mathbf{R} \mathbf{w}_{\varepsilon}$$

(三) 多信号分类波束形成器MUSIC

多信号分类: **M**Ultiple **S**ignal **C**lassification

★ 信号矩阵与噪声矩阵分离需估计源数

$$P_{MU}(\theta) = \frac{1}{\mathbf{a}^*(\theta) \mathbf{E}_N \mathbf{E}_N^* \mathbf{a}(\theta)}$$

$$\begin{aligned} \mathbf{S} &= \mathbf{A} \mathbf{P} \mathbf{A}^* + \lambda_{\min} \mathbf{S}_0 \quad \lambda_{\min} \geq 0 \\ \mathbf{S} \mathbf{e}_i &= \lambda_i \mathbf{S}_0 \mathbf{e}_i \end{aligned} \quad \left. \begin{array}{l} \\ \end{array} \right\} \mathbf{A}^* \mathbf{e}_i = 0$$

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_M \end{bmatrix} = [\mathbf{a}(\theta_1) \quad \mathbf{a}(\theta_2) \quad \cdots \quad \mathbf{a}(\theta_D)] \cdot \begin{bmatrix} F_1 \\ F_2 \\ \vdots \\ F_D \end{bmatrix} + \begin{bmatrix} W_1 \\ W_2 \\ \vdots \\ W_M \end{bmatrix}$$

$$\mathbf{X} = \mathbf{A} \mathbf{F} + \mathbf{W}$$

$$\mathbf{S} = \overline{\mathbf{X} \mathbf{X}^*} = \mathbf{A} \overline{\mathbf{F} \mathbf{F}^*} \mathbf{A} + \mathbf{W} \mathbf{W}^*$$

$$\mathbf{S} = \mathbf{A} \mathbf{P} \mathbf{A}^* + \lambda \mathbf{S}_0$$

(四) 方法对比

ordinary beamforming (BF)

maximum likelihood (ML)


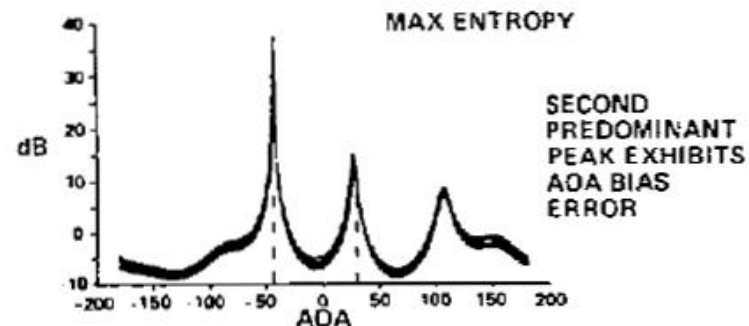
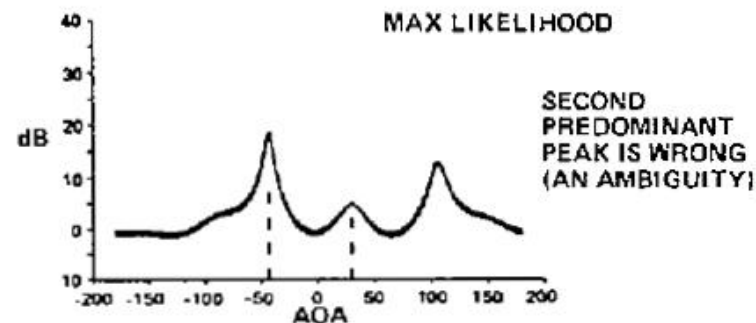
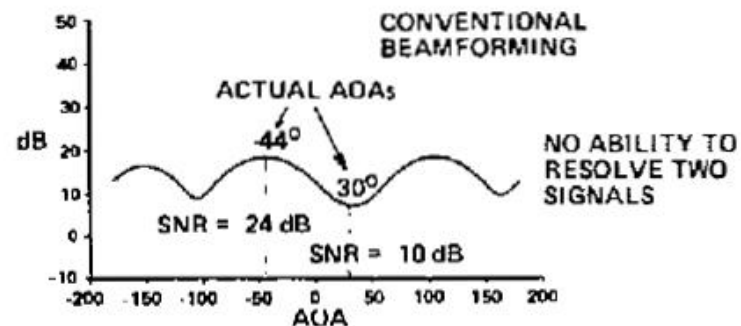
maximum entropy (ME)

$$P_{BF}(\theta) = a^*(\theta) S a(\theta)$$

$$P_{ML}(\theta) = \frac{1}{a^*(\theta) S^{-1} a(\theta)}$$

$$P_{ME}(\theta) = \frac{1}{a^*(\theta) c c^* a(\theta)}$$

$$P_{MU}(\theta) = \frac{1}{a^*(\theta) E_N E_N^* a(\theta)}$$



(五) 经典论文

- 【1】 J. Capon, "High resolution frequency-wavenumber spectrum analysis," Proc. IEEE, vol. 57, no. 8, Aug. 1969.
- 【2】 Pisarenko, V. F. "The retrieval of harmonics from a covariance function," Geophysics, J. Roy. Astron. Soc., vol. 33, pp. 347-366, 1973.
- 【3】 Schmidt, R.O, "Multiple Emitter Location and Signal Parameter Estimation," IEEE Trans. Antennas Propagation, Vol. AP-34 (March 1986), pp.276-280.